

Prévoir le chômage américain : six modèles, douze horizons, et le pari que 2021 laissait ouvert

Guillaume Vaudescal · 2026-08-31 · [Guilou001/uqam-prevision-facteurs](#)

Travail pratique d'équipe remis le 31 octobre 2021 à Philippe Goulet Coulombe, dans le cours *Applications de modèles économiques* (ECO8086, UQAM). Il est rendu ici reproductible : données retéléchargées par script, ligne de commande, tests, CI, et chaque figure régénérable d'une commande.

Le même contenu en PDF : [rapport/rapport.pdf](#).

Résultat en une phrase. La réplication retrouve le travail de 2021 de près. L'autorégressif direct d'ordre 4 à l'horizon 4 donne **0,841** contre 0,840 alors, et le **VAR à l'horizon 1 reste le meilleur des six modèles**, à 0,798 du repère contre 0,822. Le travail laissait au temps une question, faut-il retirer la Covid des données pour prévoir la suite. Cinq ans plus tard, la réponse est **oui pour les trois modèles rejoués**, et l'écart va jusqu'à la moitié de l'erreur quadratique moyenne pour l'ARMA (0,020 contre 0,041).

English summary. Six models forecast the monthly change in the US unemployment rate over twelve horizons, each re-estimated 732 times in a pseudo-out-of-sample exercise on 1961-2021 data. The replication matches the 2021 coursework closely: the direct AR(4) at horizon 4 scores 0.841 against 0.840 then, and the VAR at horizon 1 remains the best of the six, 0.798 against 0.822, both relative to an AR(1) benchmark. The work ended on an open question, whether to drop the Covid window when forecasting ahead. The realised unemployment rate now answers it: dropping it was better for all three models re-run, halving the mean squared error for the ARMA.

1. La question posée

Six façons de prévoir une même série se valent-elles, et laquelle survit une fois qu'on ne la juge plus sur les données qui ont servi à l'estimer ?

En mots simples : si on essaie de deviner comment le chômage américain va bouger le mois prochain, est-ce qu'un modèle compliqué fait mieux qu'une moyenne ?

La comparaison a un sens précis parce qu'un repère commun sert d'unité. Toutes les erreurs sont divisées par celle d'un **autorégressif d'ordre 1 à l'horizon 1**, le modèle le plus simple qui utilise le passé de la série. Un nombre sous 1 veut dire mieux que ce repère, un nombre au-dessus veut dire pire.

2. La méthode et les conclusions de 2021

Ce que le travail cherche, et sur quelles données

Dans notre travail de prévision d'une variable macroéconomique, nous avons décidé de prévoir le chômage des États-Unis.

[...]

D'autre part, ces données sont mensuelles, et disponible de février 1948 à Août 2021. Bien que l'échantillon soit disponible depuis les années 40, nous avons décidé de garder seulement les observations à partir de 1961. En effet, nous avons pris cette décision en raison de l'absence de certaines variables exogène indispensable à d'autres modèle de 1948 à 1961. Il est impératif de faire cela afin de comparer les modèles sur un pied d'égalité.

Enfin, toujours dans une optique de description des données, on peut souligner que la première différence du chômage semble stationnaire d'ordre 2, à l'exception de la période de la Covid-19 (2020-02 à 2021-06).

Le protocole

Dans cette première partie nous allons estimer et évaluer 3 modèles obligatoires, soit la moyenne historique, l'autorégressif direct et le modèle à facteur, ainsi que nos 3 meilleurs modèles optionnels qui sont ARMA, ARDL et VAR.

Nos données d'entraînements sont de 1961-01 à 2014-12 inclusivement, et nos données pour le test (ou le pseudo out of sample) sont de 2015-01 à 2021-01 inclusivement. Il est important de noter que chaque modèle a été estimé 732 fois (61 périodes fois 12 horizons), de ce fait les données d'entraînements ont été rajoutées à chacune des 61 périodes. Les horizons sont modélisés simplement en modifiant les positions des inputs du modèle (sauf pour la moyenne historique). Enfin, dans une optique de faciliter la comparaison de la performance des modèles, toutes les MSE sont exprimés par leur rapport sur notre MSE benchmark qui est un AR(1) d'horizon 1.

Les six modèles, et ce qu'ils ont donné

Comme nous avons vu en cours, la moyenne historique rend quand même des résultats impressionnants bien qu'elle ne capture pas la variance de notre variable. En effet, elle minimise mieux les erreurs en moyenne que notre benchmark. On peut noter qu'en moyenne la moyenne historique à une MSE 10 point de pourcentage inférieur au benchmark.

[...]

Le modèle autorégressif est une modélisation d'une série temporelle en fonction d'une constante et de ses valeurs passées. Afin de choisir le bon ordre de notre modèle autorégressif, nous avons comparé les modèles d'ordre 1 à 12 et gardé celui avec le meilleur BIC. Ainsi le meilleur modèle est un AR(4).

[...]

Le modèle optimal utilise 2 composantes, les deux lags de la première composante et les 5 lags de la deuxième composante respectivement, ainsi qu'un lag de la série elle-même.

[...]

On peut noter qu'en moyenne la performance du modèle à facteur est meilleur que le AR(1) benchmark. Toutefois, il est moins performant que les deux précédents modèles, à savoir la moyenne historique et l'autorégressif direct. Enfin, le meilleur horizon est h1 (0.938159).

[...]

On remarque que le modèle ARMA (1,2) performe relativement moins bien que les précédents modèles présentés. Cependant il reste sensiblement meilleur que le AR(1) benchmark. Enfin le meilleur horizon est h4 (0.901306).

[...]

On peut noter que le modèle ARDL performe relativement bien comparés aux précédents modèles présentés. En effet, en moyenne chacun de ses horizons est plus performant que le benchmark. Enfin le meilleur horizon est h1 (0.867007).

[...]

On peut observer que le modèle VAR performe relativement bien comparés aux précédents modèles présentés. En effet, en moyenne chacun de ses horizons est plus performant que le benchmark. Également on peut préciser l'excellente performance de l'horizon h1 (0.821966) comparativement aux autres modèles.

Le classement, et la faiblesse commune

Ainsi, après avoir passés en revus plusieurs modèles afin de prédire la première différence du taux de chômage, on peut noter que les 3 meilleurs modèles comparativement au benchmark, sont : Le VAR h1, le AR(4) h4 et le ARDL h1. De surcroît, tous les modèles semblent bien minimiser la somme des erreurs mais, ne capture pas adéquatement notre variance de notre variable d'intérêt.

[...]

On voit rapidement que les prévisions ont une variance beaucoup plus petite que les valeurs réelles. Également, celui qui capture le mieux la variance est le modèle VAR, comme on peut le voir avec les deux graphiques ci-dessous.

La question laissée ouverte

Dans cette partie, notre objectif est de faire du out-of-sample forecast de la première différence du taux de chômage américain pour la période de 2021-09 à 2022-09. Tous les meilleurs modèles présentés dans la section précédente ont été réestimés deux fois, la première avec les données de 1961-01 à 2021-08 et la deuxième avec cette même période mais en retirant a période d'extrême volatilité dû à la pandémie de covid-19. (2020-02 à 2021-06).

[...]

Ce constat amène une question importante pour la prévision. Que devrions-nous faire des données résultats de black swan pour la prévision ? Il semble logique d'exclure ces valeurs aberrantes pour approximer le processus générateur de données. Pour confirmer ou infirmer cette hypothèse, il faudrait comparer ces deux cas à travers plusieurs modèles dans un exercice pseudo out of sample. Pour nos prévisions, il faudra attendre quelques mois pour voir la meilleure approche.

3. Les données, et ce qu'il a fallu rebâtir

Le carnet de 2021 lisait deux fichiers déposés à la main. Les deux se retéléchargent, l'un tel quel, l'autre dans un millésime différent.

Source	Contenu	Fenêtre retenue	Statut
FRED UNRATE , transformation chg	variation d'un mois à l'autre du taux de chômage américain	1961-01 à 2021-08, 728 mois	mesuré
FRED-MD, millésime courant	119 séries mensuelles américaines complètes sur la fenêtre, transformées par leur propre code	1961-01 à 2021-08	mesuré, millésime substitué

Comment lire ce tableau, en trois constats. D'abord, les 728 mois retrouvent exactement la fenêtre du travail. Les positions que le carnet de 2021 écrivait en clair, 155 pour janvier 1961 et 803 pour janvier 2015, tombent sur les mêmes dates, et un test le vérifie. Ensuite, 119 des 126 séries de FRED-MD sont complètes sur la fenêtre, les sept autres étant retirées. Enfin, le millésime de septembre 2021, celui qu'avait le cours, n'est pas téléchargeable : l'adresse par millésime renvoie une page d'erreur et l'archive officielle s'arrête en décembre 2014, deux constats mesurés le 2026-08-29. Le millésime courant sert de substitut, tronqué à août 2021, et ses valeurs anciennes sont révisées.

Une ambiguïté du travail, tranchée par ses propres chiffres. Le texte de 2021 parle partout de « la première différence du taux de chômage ». Mais la colonne du carnet s'appelle [UNRATE_PCH](#), un nom qui désigne la variation en pourcentage. Les deux ne sont pas la même chose : la première retranche le taux du mois précédent, la seconde le divise. La moyenne historique publiée en 2021, -0,001925, est celle de

la différence première ; la variation en pourcentage donnerait un nombre d'un tout autre ordre. Ce dépôt télécharge donc la différence première, et la moyenne obtenue sur les données révisées, $-0,002060$, en est à un dix-millième.




Fig. 1. – Le chômage et la fenêtre de la Covid

Comment lire cette figure : chaque point est la variation du taux de chômage d'un mois à l'autre, en points de pourcentage. La bande colorée est la fenêtre de février 2020 à juin 2021 que le travail met de côté dans sa seconde variante. Le pic d'avril 2020, 10,4 points, vaut à lui seul 11,6 fois le plus fort mouvement mensuel observé hors de cette fenêtre, 0,9 point en janvier 1975. C'est ce qui explique pourquoi la question de le retirer se pose.

4. La méthode, pas à pas

1. **Choisir la variable à prévoir** : la variation mensuelle du taux de chômage, désaisonnalisée par la source et stationnaire, c'est-à-dire dont la moyenne et la variance ne dérivent pas dans le temps.
2. **Couper l'échantillon** : 1961-01 à 2014-12 pour l'apprentissage, soit 648 mois, puis 61 fenêtres de test qui commencent en 2015-01. À chaque fenêtre, un mois de plus entre dans l'apprentissage.
3. **Prévoir de façon directe**. Pour l'horizon h , les deux autorégressifs ne gardent que les retards h et suivants, puis prédisent le mois qui suit la fin de leur fenêtre. Celui d'horizon 4 ne voit donc jamais les trois mois qui précèdent immédiatement ce qu'il prédit, et un test le vérifie en recomposant la prévision à la main depuis les quatre valeurs retardées. Les quatre autres modèles décalent moins. L'ARMA ne décale que son retard autorégressif, et garde les résidus des deux mois précédents. L'ARDL et le modèle à facteurs décalent de même leur retard du chômage, mais gardent leurs séries explicatives sans décalage. Le VAR n'est pas direct du tout : il est prolongé de h mois à partir des dernières observations.
4. **Répéter 732 fois par modèle**, 12 horizons fois 61 fenêtres.
5. **Estimer les six modèles** : la moyenne de tout le passé ; l'autorégressif direct d'ordre 4 ; le modèle à facteurs ; l'ARMA (1, 2) ; l'ARDL ; le VAR. Le modèle à facteurs résume les 119 séries de FRED-MD en deux composantes principales, les directions qui expliquent le plus de leur variation commune. L'ARDL ajoute les demandes d'assurance chômage et l'emploi salarié. Le VAR traite le chômage et les demandes d'assurance chômage comme deux variables qui s'expliquent mutuellement.
6. **Rapporter chaque erreur à celle du repère**, l'autorégressif d'ordre 1 à l'horizon 1.

5. Ce que le portage a changé

Ce que faisait le carnet de 2021	Ce que fait ce dépôt	Pourquoi
----------------------------------	----------------------	----------

positions de ligne écrites en clair
(155, 803, 864)

dates (1961-01, 2015-01,
2020-02)

une série qui s'allonge décale toutes
les positions ; les dates ne bougent
pas

colonnes de FRED-MD désignées
par leur rang (iloc[:, 30:32])

désignées par leur nom (CLAIMSx,
PAYEMS)

le rang d'une colonne dépend du
millésime

deux fichiers déposés à la main

pmf fetch

le dépôt doit se rejouer ailleurs

6. Les résultats

Tous les chiffres viennent de [results/tables/](#), et les figures se régénèrent par `pmf figures`.

La table complète : erreur de chaque modèle, rapportée au repère

Horizon	Moyenne historique	Autorégressif d'ordre 1	Autorégressif direct d'ordre 4	Modèle à facteurs	ARMA (1, 2)	ARDL	VAR
1	0,931	1,000	0,955	1,000	0,958	0,841	0,798
2	0,931	0,996	0,950	1,012	0,951	0,875	1,007
3	0,931	1,032	0,890	1,013	1,048	0,882	0,975
4	0,930	0,854	0,841	0,988	0,932	0,837	1,046
5	0,931	0,991	0,925	1,018	1,022	0,880	0,922
6	0,931	0,861	0,899	0,978	0,931	0,827	0,933
7	0,932	0,934	0,987	1,015	0,993	0,871	0,885
8	0,932	0,993	0,954	1,024	1,066	0,894	0,951
9	0,931	0,934	0,856	1,009	0,999	0,875	0,931
10	0,932	0,893	0,853	1,028	0,962	0,885	0,920
11	0,933	0,908	0,953	0,996	0,976	0,845	0,907
12	0,933	0,921	0,953	0,998	0,964	0,855	0,923
Moyenne	0,931	0,943	0,918	1,007	0,983	0,864	0,933

Comment lire ce tableau, en quatre constats. D'abord, cinq des six modèles battent le repère en moyenne, et le sixième, le modèle à facteurs, fait pire : résumer 119 séries en deux composantes n'aide pas à prévoir cette série-là. Ensuite, l'ARDL est le plus bas de façon constante : il tient le meilleur score du tableau à neuf des douze horizons, et 0,864 en moyenne. Le VAR, lui, tient le meilleur score du tableau à l'horizon 1 et passe au-dessus du repère aux horizons 2 et 4. Sa colonne ne se compare pas d'un horizon à l'autre, pour la raison donnée dans les limites. Puis, la moyenne historique tient la ligne la plus plate des sept, autour de 0,931 : ne rien modéliser du tout coûte 7 % de moins que le repère. Enfin, l'écart entre le meilleur et le pire modèle vaut 0,143 en moyenne, ce qui est petit au regard de 61 mois de test. Le travail de 2021 le disait déjà, en proposant des tests statistiques comme extension.




Fig. 2. – Les erreurs par horizon

Comment lire cette figure : six courbes, une par modèle, le repère n'ayant pas la sienne. L'horizon est en abscisse, l'erreur rapportée au repère en ordonnée. La ligne pointillée à 1 est le repère lui-même, l'autorégressif d'ordre 1 à l'horizon 1. La ligne bleue presque horizontale est la moyenne historique, qui ne dépend pas de l'horizon. Les courbes qui zigzaguent sont celles des modèles estimés, et leur zigzag mesure surtout le bruit de l'exercice, pas une propriété des horizons. La courbe du VAR fait exception : son décalage d'horizon, décrit dans les limites, y contribue aussi.

Ce que 2021 rapporte, et ce que 2026 retrouve

Constat de 2021	2021	2026	Écart
Autorégressif direct d'ordre 4, horizon 4	0,840	0,841	0,001
VAR, horizon 1	0,822	0,798	–0,024
ARDL, horizon 1	0,867	0,841	–0,026
ARMA, horizon 4	0,901	0,932	0,031
Modèle à facteurs, horizon 1	0,938	1,000	0,062
Moyenne historique, écart moyen au repère	10 points	6,9 points	3,1 points

Comment lire ce tableau, en trois constats. Le premier est que l'autorégressif direct tombe à un millième près, ce qui est le meilleur résultat possible pour une répliation faite sur des données révisées et un millésime de FRED-MD différent. Le deuxième est que le VAR reste le meilleur modèle du lot dans les deux versions, et qu'il s'améliore même de 0,024. Le troisième est que le modèle à facteurs est celui qui bouge le plus, ce qui était prévisible. C'est le seul dont les entrées dépendent entièrement du millésime substitué, et il passe de 0,938 à 0,9998, soit le niveau du repère.

Le classement de tête change en partie. Le travail de 2021 retenait « le VAR h1, le AR(4) h4 et le ARDL h1 ». En 2026 le trio devient le VAR à l'horizon 1 (0,798), l'ARDL à l'horizon 6 (0,827) et l'ARDL à l'horizon 4 (0,837), l'ARDL à l'horizon 1 arrivant quatrième à 0,841 et l'autorégressif direct à l'horizon 4 cinquième au même arrondi. Les quatre premiers tiennent dans 0,043, soit moins d'un tiers de l'écart entre le meilleur et le pire modèle en moyenne, qui vaut 0,143.

Le pari de 2021, et sa réponse

Le travail se terminait sur une question et un délai : faut-il retirer la Covid des données, et « il faudra attendre quelques mois pour voir la meilleure approche ». Les mois ont passé. Le chômage réalisé de septembre 2021 à septembre 2022 est maintenant connu, et il tranche.

Modèle	Erreur quadratique moyenne, avec la Covid	Sans la Covid	Ce que le retrait fait gagner
Moyenne historique	0,0380	0,0372	2 %
Autorégressif direct d'ordre 4	0,0430	0,0314	27 %
ARMA (1, 2)	0,0412	0,0204	50 %

Comment lire ce tableau, en trois constats. Le premier répond à la question de 2021 : retirer la fenêtre de la Covid était le bon choix, pour les trois modèles rejoués, et l'intuition du travail était donc juste. Le deuxième est que le gain croît quand le modèle pèse davantage les mois récents. Il vaut 2 % pour la moyenne historique, qui dilue les dix-sept mois dans sept cents, et 50 % pour l'ARMA, dont les paramètres tiennent surtout aux dernières observations. Ces pourcentages portent sur l'erreur au carré ; ramenés à sa racine, le gain de l'ARMA vaut 29,6 %. Le troisième est plus embarrassant, pour les six variantes à la fois. Leur erreur moyenne est positive dans les six cas, de +0,04 à +0,13 point : aucune n'a vu que le chômage continuerait de baisser aussi vite en 2022.

Trois modèles sur six sont rejoués, ceux qui ne demandent aucune prévision auxiliaire. Le modèle à facteurs, l'ARDL et le VAR auraient besoin qu'on prévoie d'abord leurs propres variables explicatives, ce que le carnet de 2021 faisait par des ARMA auxiliaires ; ils ne sont pas prolongés ici.




Fig. 3. – Le pari de 2021

Comment lire cette figure : un cadre par modèle, la courbe noire étant le chômage réellement observé, les deux autres les prévisions faites en 2021 avec et sans la fenêtre de la Covid. Les prévisions sont presque plates quand le réalisé oscille entre -0,4 et +0,1 point. C'est la faiblesse que le travail de 2021 signalait lui-même, « les prévisions ont une variance beaucoup plus petite que les valeurs réelles ». La courbe verte, sans la Covid, passe sous la jaune sur 38 des 39 mois dessinés, et c'est ce décalage vers le bas qui la rapproche du réalisé. Dans le cadre de la moyenne historique les deux se superposent, l'écart n'y valant que 0,0033 point.

7. Reproduire

```
uv sync --locked --all-extras
uv run pytest                # 13 tests fermés, sans réseau
uv run pmf fetch             # deux fichiers sources, environ 0,7 Mo
uv run pmf bases             # la fenêtre et le découpage
uv run pmf lab               # les six modèles, 732 estimations chacun
```



```
uv run pmf futur          # les prévisions de 2021, contre le réalisé
uv run pmf figures        # les trois figures
```

Durées mesurées sur un processeur Apple M5 Pro : **89 secondes** pour `pmf lab`, dont 62 pour l'ARMA, qui est le seul modèle à réestimer une vraisemblance complète à chacune des 732 fenêtres. Les autres commandes prennent quelques secondes.

8. Limites, avec leur statut

Limite	Statut
Le millésime de FRED-MD de septembre 2021 n'est pas téléchargeable, l'archive officielle s'arrêtant en décembre 2014	mesuré le 2026-08-29 ; le millésime courant sert de substitut et le modèle à facteurs est celui qui en dépend le plus
Les valeurs du chômage sont révisées depuis 2021	mesuré : la moyenne historique passe de $-0,001925$ à $-0,002060$, soit un écart d'un dix-millième
Le texte de 2021 annonce un test de 2015-01 à 2021-01, alors que son code et ses figures s'arrêtent en 2020-01	mesuré ; les 61 fenêtres du code sont retenues, comme dans les figures du travail
Les ordres des modèles (AR(4), ARMA (1, 2), les retards de l'ARDL) sont ceux que le BIC retenait en 2021, repris tels quels	déclaré ; les resélectionner sur les données révisées changerait la comparaison plus que le passage du temps
Aucun test statistique ne distingue les modèles entre eux	reconnu ; le travail de 2021 le proposait déjà comme extension, et les quatre premiers couples tiennent dans 0,043
La moyenne historique de l'horizon h s'arrête h mois plus tôt que les autres modèles	reconnu ; c'est un raccourci du carnet de 2021, conservé pour rester fidèle, et il avantage à peine la moyenne aux grands horizons
Le VAR n'est pas direct : à l'horizon H il prévoit le mois $t + H - 1$, et son erreur est mesurée contre le mois t	mesuré ; le carnet de 2021 apparie de la même façon, donc la réplication est fidèle, et c'est la comparaison d'un horizon à l'autre qui perd son sens pour cette colonne
Trois des six modèles seulement sont prolongés jusqu'en 2022	déclaré ; les trois autres exigeraient de prévoir leurs propres variables explicatives
Un seul pays, une seule variable, un seul découpage	déclaré

9. Crédits, licence, citation

Travail d'équipe réalisé par **Guillaume Vaudescal et Philippe Tousignant**, remis le 31 octobre 2021. Cours ECO8086, *Applications de modèles économiques*, donné par Philippe Goulet Coulombe à l'UQAM. Le portage sur statsmodels 0.14, le téléchargement par script, les tests, la CI et le prolongement jusqu'en 2022 datent de 2026.

Données : Federal Reserve Bank of St. Louis, série UNRATE et base FRED-MD de McCracken et Ng, téléchargées par script et jamais committées. Code sous licence MIT.

10. Références

- Kuma, J. K. (2018), *Modélisation ARDL, test de cointégration aux bornes et approche de Toda-Yamamoto*, Congo-Kinshasa, cel-01766214.
- Marcellino, M. (2017), *An introduction to factor modelling*, université Bocconi.
- McCracken, M. W. et Ng, S. (2016), « FRED-MD: a monthly database for macroeconomic research », *Journal of Business and Economic Statistics*, vol. 34, n° 4, p. 574-589.
- U.S. Bureau of Labor Statistics, *Unemployment Rate* [UNRATE], FRED, Federal Reserve Bank of

St. Louis, <https://fred.stlouisfed.org/series/UNRATE>.